Tarea Minería de Datos y Modelización Predictiva

Guillermo Díaz Aguado

In [97]:
```
import pandas as pd
import numpy as np
from collections import defaultdict
from scipy.stats import chi2_contingency
import matplotlib.pyplot as plt
import seaborn as sns
import statsmodels.api as sm
import itertools
from sklearn.model_selection import train_test_split
from sklearn.preprocessing import LabelEncoder
from FuncionesMineria import (patron_perdidos, ImputacionCuant, ImputacionCuali,
                              hist_targetbinaria, Transf_Auto, lm, lm_stepwise, lm_
                              modelEffectSizes, crear_data_modelo,analizar_variable
                              hist_target_categorica)

pd.set_option('display.max_columns', None)
pd.set_option('display.max_rows', None)
```

1. Introducción al objetivo del problema y las variables implicadas.

Realizaremos un estudio sobre el modelado la abstención de voto en una base de datos que contiene información sobre los distintos municipios. La abstención, considerada como variable dependiente, se evalúa desde dos perspectivas: una dicotómica (1 si el porcentaje es mayor a 30, 0 en caso contrario) y otra continua (porcentaje de abstenciones).

Uno de los objetivos del estudio es ver si tanto para la variable dicotomica como para la continua, los modelos siguen escogiendo las mismas varibles independientes y de ser así, cual sería el peso de estas variables. Tambíen será interesente cual tiene menos error y si usan el mismo modelo o no.

La verdad es que he tenido muchos problemas que no he sido capaz de solucionar debido al tiempo y a la dificultad implicada. Por más que intentase que funcionará las funciones de lm, ninguna me salía, todas y paraban en alguna interacción del "for" debido a que supuestamente se modificaba las inputs de alguna manera que no he conseguido descubrir. Y aunque usé en su día el entorno especificado, a la larga me estaba dando más problemas que soluciones, por lo que algunas funciones las he tenido que arreglar a mano y otras no he sido capaz. Sé que me dejo a medias la parte más importante del trabajo, y lo siento mucho pero estoy en un callejón sin salida, tal vez debería haber acudido a su ayuda, pero siempre creía que lo podía solucionar, he pecado de sabelotodo. Entre todo esto y el curro, llevo unas semanas que no daba a basto, al

final esto es todo lo que puedo hacer. Puede parecer que he dejado de lado la asignatura pero de verdad que no, he dado todo hasta el final, me gustaría poder tener las gráficas y los modelos para poder expresar mis conocimientos pero no he podido.

2. Importación de los datos y asignación correcta de los tipos de las variables.

Primer paso de todo el proyecto: Leemos del excel los datos y lo guardamos en la variable **df**.

In [52]:
```
df = pd.read_excel("DatosEleccionesEspaña.xlsx", sheet_name="DatosEleccionesEspa
df.head(10)
```

Out[52]:

	Name	CodigoProvincia	CCAA	Population	TotalCensus	AbstentionPtge	A
0	Abadía	10	Extremadura	336	282	20.213	
1	Abertura	10	Extremadura	429	364	25.275	
2	Acebo	10	Extremadura	569	569	27.241	
3	Acehúche	10	Extremadura	822	704	30.114	
4	Aceituna	10	Extremadura	623	540	30.185	
5	Ahigal	10	Extremadura	1421	1263	22.565	
6	Alagón del Río	10	Extremadura	923	826	30.024	
7	Albalá	10	Extremadura	730	629	27.027	
8	Alcántara	10	Extremadura	1571	1320	22.803	
9	Alcollarín	10	Extremadura	256	266	24.436	

3. Analisis descriptivo del conjunto de datos.

El análisis descriptivo de datos en un DataFrame es un paso clave para comprender la estructura, distribución y posibles problemas en los datos antes de aplicar modelo. Realizaremos los siguientes pasos:

1. Inspección general del DataFrame.
2. Analísis de Variables númericas.
3. Analísis de Variables categóricas.

3.1. Inspección general del DataFrame.

Vamos a revisar la asignación correcta de los tipos de las variables. Un paso relativamente sencillo que nos puede ayudar a detectar posibles errores futuros con tan solo un poco de esmero.

In [53]:
```
df.dtypes
```

Out[53]:
```
Name                          object
CodigoProvincia                int64
CCAA                          object
Population                     int64
TotalCensus                    int64
AbstentionPtge               float64
AbstencionAlta                 int64
Izda_Pct                     float64
Dcha_Pct                     float64
Otros_Pct                    float64
Izquierda                      int64
Derecha                        int64
Age_0-4_Ptge                 float64
Age_under19_Ptge             float64
Age_19_65_pct                float64
Age_over65_pct               float64
WomanPopulationPtge          float64
ForeignersPtge               float64
SameComAutonPtge             float64
SameComAutonDiffProvPtge     float64
DifComAutonPtge              float64
UnemployLess25_Ptge          float64
Unemploy25_40_Ptge           float64
UnemployMore40_Ptge          float64
AgricultureUnemploymentPtge  float64
IndustryUnemploymentPtge     float64
ConstructionUnemploymentPtge float64
ServicesUnemploymentPtge     float64
totalEmpresas                float64
Industria                    float64
Construccion                 float64
ComercTTEHosteleria          float64
Servicios                    float64
ActividadPpal                 object
inmuebles                    float64
Pob2010                      float64
SUPERFICIE                   float64
Densidad                      object
PobChange_pct                float64
PersonasInmueble             float64
Explotaciones                  int64
dtype: object
```

Por lo que podemos observar, las siguientes variables tienen el error de ser `float` cuando deberian ser `int` (no tiene sentido tener un tercio de empresa en un municipio):

- totalEmpresas
- Industria
- Construccion
- ComercTTEHosteleria
- Servicios
- inmuebles
- Pob2010

- SUPERFICIE Realmente este error no es notable, puesto que las variables de tipo `float` se comportan de manera muy similar a las variables de tipo `int`

En la siguiente celda generamos un código que nos cuenta cuantas filas tienen este error, si fuese un error puntual se verificaría para cada caso antes de convertirlo todo a `int`, pero se puede ver que pasa en todas las columnas.

In [54]:
```
mal_tipificadas = ['totalEmpresas', 'Industria', 'Construccion', 'ComercTTEHoste
                   'Servicios', 'inmuebles', 'Pob2010', 'SUPERFICIE']
for col in mal_tipificadas:
    print(f"Tenemos un total de {len(df[df[col].apply(lambda x: isinstance(x, fl
```

```
Tenemos un total de 8117 elementos que son de tipo *float* en totalEmpresas
Tenemos un total de 8117 elementos que son de tipo *float* en Industria
Tenemos un total de 8117 elementos que son de tipo *float* en Construccion
Tenemos un total de 8117 elementos que son de tipo *float* en ComercTTEHosteleria
Tenemos un total de 8117 elementos que son de tipo *float* en Servicios
Tenemos un total de 8117 elementos que son de tipo *float* en inmuebles
Tenemos un total de 8117 elementos que son de tipo *float* en Pob2010
Tenemos un total de 8117 elementos que son de tipo *float* en SUPERFICIE
```

In [55]:
```
# Simplemente cambiaré los tipos de estas variables
for var in mal_tipificadas:
    df[var] = df[var].astype(float)
```

In [56]:
```
# Voy a guardar el tipo de valores guardados en cada variable
numericas = df.select_dtypes(include=['int', 'int32', 'int64','float', 'float32'
categoricas = df.select_dtypes(include=['object']).columns
print(categoricas)
categoricas = [x for x in categoricas if x != 'Name']
```

```
Index(['Name', 'CCAA', 'ActividadPpal', 'Densidad'], dtype='object')
```

He eliminado los datos de `name` porque al final el nombre de los munipicios se puede entender como el ID de cada registro y no nos dará ninguna información, además de que será mas sencillo trabajar con los índices de los DataFrames de Pandas.

Como último paso de la inspección voy a mostrar estadísticas generales de todas las variables, y así poder ver de manera general los datos.

In [57]:
```
df.describe()
```

Out[57]:

	CodigoProvincia	Population	TotalCensus	AbstentionPtge	AbstencionAlta	8
count	8117.000000	8.117000e+03	8.117000e+03	8117.000000	8117.000000	
mean	26.664654	5.722345e+03	4.247864e+03	26.501647	0.311199	
std	14.893449	4.620418e+04	3.442344e+04	7.533438	0.463012	
min	1.000000	5.000000e+00	5.000000e+00	0.000000	0.000000	
25%	13.000000	1.660000e+02	1.400000e+02	21.678000	0.000000	
50%	26.000000	5.480000e+02	4.470000e+02	26.424000	0.000000	
75%	41.000000	2.427000e+03	1.843000e+03	31.471000	1.000000	
max	50.000000	3.141991e+06	2.363829e+06	57.576000	1.000000	

3.2. Analísis de Variables númericas.

Realizaremos un analísis de las varibles númericas para ver si algún campo se debería convertir en categoríca. En la información proporcionada por nuestro excel podemos intuir que la única variable número que se podría caracterizar como categoríca sería: "CodigoProvincia". De todas formas, vamos a realizar el anlísis.

In [58]:
```
numericas_df = df[numericas]
numericas_unicas = numericas_df.apply(lambda col: len(col.unique()))
numericas_unicas_df = pd.DataFrame({'Columna': numericas_unicas.index, 'Distinto
numericas_unicas_df[numericas_unicas_df["Distintos"]<60]
```

Out[58]:

	Columna	Distintos
0	CodigoProvincia	50
4	AbstencionAlta	2
8	Izquierda	2
9	Derecha	2

Tenemos un pequeño problemilla con "CodigoProvincia" y es que tenemos muchos valores, pero es categorica. Con lo que: ¿Como agrupamos esta categorica?, Expongo unas cuantas soluciones y al lado los posibles problemas que puedan darse al utilizar esa agrupacion.

- Categorizar por CCAA: Pero esto daría un problema claro de colinealidad perfecta, porque es la misma que la variable "CCAA"
- Categorizar por cantidad de habitantes en la provincia (Suma de "Population"): Podría darse una colinealidad con la población, pero nos puede mostrar una realacion con las provincias mas pobladas. Y aunque no nos de una **dependencia lineal** con las variables de densidad y superficie, si que existira una relacion entre estos, ya que siguen la formula: $Densidad = \frac{Poblacion}{Superficie}$

No se me ha ocurrido ninguna otra posible realción, por lo que he decido eliminarla, ya que siempre me dará alguna relación.

3.3. Analísis de las Variables categoricas.

In [59]:
```
categoricas_dfs = []
for categoria in categoricas:
    categoricas_n = df[categoria].value_counts()
    categoricas_per = df[categoria].value_counts(normalize=True)

    temp_df = pd.DataFrame({
        "n": categoricas_n,
        "%": categoricas_per
    })

    temp_df.index = pd.MultiIndex.from_product([[categoria], temp_df.index], nam

    categoricas_dfs.append(temp_df)

categoricas_df = pd.concat(categoricas_dfs)

categoricas_df
```

Out[59]:

Categoria	Valor	n	%
CCAA	**CastillaLeón**	2248	0.276950
	Cataluña	947	0.116669
	CastillaMancha	919	0.113219
	Andalucía	773	0.095232
	Aragón	731	0.090058
	ComValenciana	542	0.066773
	Extremadura	387	0.047678
	Galicia	314	0.038684
	Navarra	272	0.033510
	PaísVasco	251	0.030923
	Madrid	179	0.022052
	Rioja	174	0.021436
	Cantabria	102	0.012566
	Canarias	88	0.010841
	Asturias	78	0.009609
	Baleares	67	0.008254
	Murcia	45	0.005544
ActividadPpal	**Otro**	4932	0.607614
	ComercTTEHosteleria	2538	0.312677
	Servicios	620	0.076383
	Construccion	14	0.001725
	Industria	13	0.001602
Densidad	**MuyBaja**	6416	0.790440
	Baja	1053	0.129728
	Alta	556	0.068498
	?	92	0.011334

En la parte de "ActividadPpal" podemos llegar a tener un problemilla, y es que este campo puede crear colinealidad. El campo "ActividadPpal" lo que hace es marcar con una etiqueta la actividad que más se desarrolla en cada municipio. Esto lo resolveremos en el apartado 7

Una vez arreglado el dataframe vamos a guardar la variables dependientes en objetos de *pd.Series*:

- **Y_cont** -> Para la variable dependiente continua
- **Y_dico** -> Para la variable dependiente dicotomica

Para luego después eliminar todas las posibles variables dependientes y así crear el dataframe que contiene unicamente las variables independientes. También he borrado la variable "Name" y la variable "CodigoProvincia", esta última explico porque la borro en el apartado 3.2.

In [60]:
```
Y_cont = df["AbstentionPtge"]
Y_dico = df["AbstencionAlta"]


out_variables_dependientes = ["AbstencionAlta",
                              "AbstentionPtge",
                              "Izda_Pct",
                              "Dcha_Pct",
                              "Otros_Pct",
                              "Izquierda",
                              "Derecha"]

X_miss = df.drop(columns=out_variables_dependientes+["Name", "CodigoProvincia"])
numericas = numericas.drop(out_variables_dependientes)
numericas = numericas.drop("CodigoProvincia")

X = X_miss
```

4. Corrección de errores detectados

Echando una visualización rápida del Database podemos observar que los valores erroneos presentes son los siguientes:

- NaN o valores nulos
- "?"
- Valores negativos en campos donde no puede existir valores negativos
- Valores igual a 99999

Creando la siguiente función podemos evaluar aquellos registros con errores

In [61]:
```
def valores_erroneos(df):
    """
    Cuenta los valores erroneos de cada variable en un dataframe
    sin tener en cuenta los valores erroneos.
    Los valores erroneos son:
        NaN o valor nulo
        "?"

    Inputs:
        df: El DataFrame que contiene los datos.

    Returns:
        Df con los valores erroneos de cada columna de cada columna
    """
    nan_values = pd.DataFrame()
    quest_mark = pd.DataFrame()
```

```
    neg_values = pd.DataFrame()
    val_9999 = pd.DataFrame()
    # Si en algún momento quisiera saber donde se encuentra cada error podria sa

    for col in df.columns:
        nan_values[col] = df[col].isna() + df[col].apply(lambda col: (col == "Na
        quest_mark[col] = df[col].apply(lambda col: (col == "?"))
        df[col] = df[col].replace('?', np.nan)
        if col in numericas and col != "PobChange_pct":
            neg_values[col] = df[col].apply(lambda col: (col < 0))
            df[col] = df[col].apply(lambda x: np.nan if x <= 0 else x)
        if col in numericas:
            val_9999[col] = df[col].apply(lambda col: (col == 99999))
            df[col] = df[col].replace(99999, np.nan)

    nan_values = nan_values.sum(axis=1)
    quest_mark = quest_mark.sum(axis=1)
    neg_values = neg_values.sum(axis=1)
    val_9999 = val_9999.sum(axis=1)

    return pd.DataFrame({"NaN": nan_values, "?": quest_mark,
                         "Valores negativos": neg_values, "Valores de 99999": va

erroneos = valores_erroneos(df)
```

In [62]:
```
# No voy a mostrar todos los valores erroneos del dataframe, ya que tiene 8000 r
# Me parece mas significativo el numero total de datos erroneos
erroneos.sum(axis=0)
```

Out[62]:
```
NaN                 701
?                    92
Valores negativos   656
Valores de 99999    189
dtype: int64
```

In [63]:
```
erroneos_fila = erroneos.sum(axis=1)
erroneos_fila = erroneos_fila[erroneos_fila>10]
len(erroneos_fila)
```

Out[63]:
```
4
```

5. Análisis de valores atípicos. Decisiones.

Las variables dicotomicas están datadas como "int64" ya que usan los valores 1 y 0. Voy a cambiarlo a True y False para una mejor visualización.

In [ ]:
```
def valores_atipicos(df, mode="intercuart"):
    # Primero seleccionaremos los datos que sean nuemricos
    numericas = df.select_dtypes(include=['int', 'int32', 'int64','float', 'floa

    if mode == "intercuart":
        atipicos = pd.DataFrame()
        for col in numericas:
            qnt = df[col].quantile([0.25, 0.75]).dropna()
            Q1 = qnt.iloc[0]
            Q3 = qnt.iloc[1]
            H = 3 * (Q3 - Q1)
```

```
            limite_inferior = Q1 - H
            limite_superior = Q3 + H

            # Los valores atipicos seran:
            atipicos[col] = (df[col]<limite_inferior) | (df[col]>limite_superior

        return atipicos.sum(axis=1)

    #if mode == "std des":
    #    atipicos = pd.DataFrame()
    #    for col in numericas:
    #        media = df[col].mean()
    #        desv = df[col].std()
    #
    #        limite_inferior = media - 3*desv
    #        limite_superior = media + 3*desv

    #        # Los valores atipicos seran:
    #        atipicos[col] = (df[col]<limite_inferior) | (df[col]>limite_superio

    if mode == "asim":
        atipicos = pd.DataFrame()
        for col in numericas:
            if abs(df[col].skew()) < 1:
                # Si es simétrica, calcula los valores atípicos basados en la de
                criterio1 = abs((df[col] - df[col].mean()) / df[col].std()) > 3
                atipicos[col] = abs((df[col] - df[col].mean()) / df[col].std())
            else:
                # Si es asimétrica, calcula la Desviación Absoluta de la Mediana
                mad = sm.robust.mad(df[col], axis=0)
                criterio1 = abs((df[col] - df[col].median()) / mad) > 8
                atipicos[col] = abs((df[col] - df[col].median()) / mad) > 8


        return atipicos.sum(axis=1)

atipicos = pd.DataFrame({"Rango Intercuartilico": valores_atipicos(df, "intercua
                         "En funcion de la asimetria": valores_atipicos(df, "asi
```

In [65]:
```
print(atipicos.sum(axis=0))
```

```
Rango Intercuartilico    9419
Desviacion estandar      6038
dtype: int64
```

6. Analisis de valores perdidos

La matriz de correlación de valores ausentes se utiliza para identificar patrones en los valores faltantes de un conjunto de datos. Su objetivo es analizar si la ausencia de datos en una columna está relacionada con la ausencia de datos en otra, lo que puede ayudar en la imputación y en la comprensión de los datos.

In [66]:
```
print(X_miss.columns)
patron_perdidos(X_miss)
```

```
Index(['CCAA', 'Population', 'TotalCensus', 'Age_0-4_Ptge', 'Age_under19_Ptge',
       'Age_19_65_pct', 'Age_over65_pct', 'WomanPopulationPtge',
       'ForeignersPtge', 'SameComAutonPtge', 'SameComAutonDiffProvPtge',
       'DifComAutonPtge', 'UnemployLess25_Ptge', 'Unemploy25_40_Ptge',
       'UnemployMore40_Ptge', 'AgricultureUnemploymentPtge',
       'IndustryUnemploymentPtge', 'ConstructionUnemploymentPtge',
       'ServicesUnemploymentPtge', 'totalEmpresas', 'Industria',
       'Construccion', 'ComercTTEHosteleria', 'Servicios', 'ActividadPpal',
       'inmuebles', 'Pob2010', 'SUPERFICIE', 'Densidad', 'PobChange_pct',
       'PersonasInmueble', 'Explotaciones'],
      dtype='object')
```

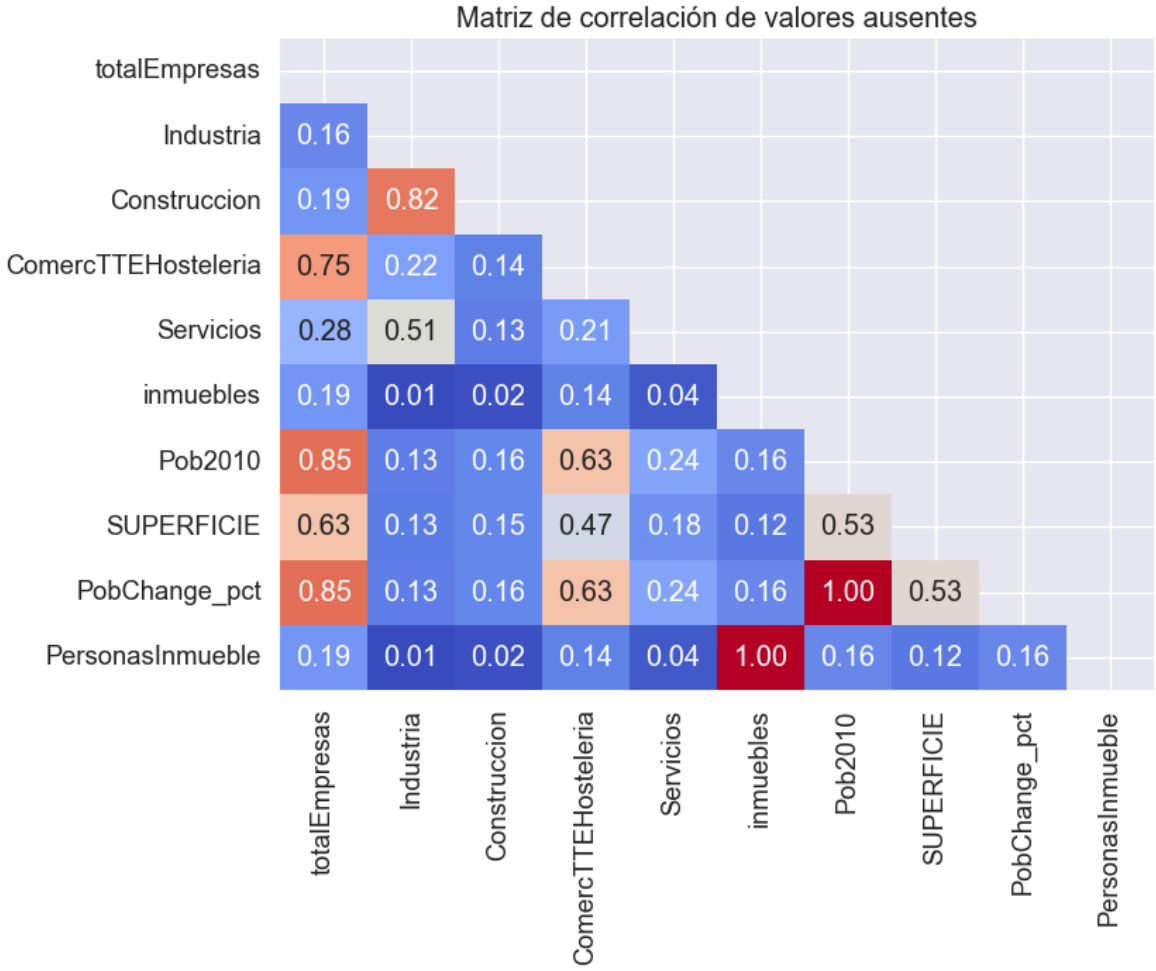

Como veremos en el apartado 7, las variables que tienen una relacion directa, suelen tener casi los mismos datos missing, veamos los mas destacados y que explicación le puedo dar:

- `inmuebles` y `PersonasInmueble` su relacion es a razón de $PersonasInmueble = \frac{Poblacion}{inmueble}$ y es muy probable que al recopilar los datos de este excel no se imputen los valores de `PersonasInmueble`, sino que simplemente un software realize la division de esos campos. Entonces al faltar el valor de inmueble, este software no podría sacar los resultados
- `PobChange_pct` y `Pob2010`, ocurre exactamente lo mismo que en el caso anterior.
- `Industria`, `Construccion`, `Servicios` y `ComercTTEHosteleria`, tienen relación entre ellos ya que en aquellos municipios donde no imputan los valores de 1 de estos campos, no suelen imputar los valores de los demás campos.

- `totalEmpresas` con otros campos tiene relación la ausencia de valores pero no soy capaz de entender cual es dicha relación.

6.1 Imputaciones

A la hora de realizar la imputación pensé que sería buena opción usar los k nearest neighbours, debido a que estamos hablando de poblaciones de personas, y es que está visto que las personas tenemos una influencia en la gente de nuestro alrededor o poblaciones que tienen varios campos parecidos, suelen compartir otros campos. Pero finalmente me decanté por la mediana, ya que la mayoría de los municipios con elementos faltantes o atípicos son poblaciones pequeñas que son las que predominan en España, y estos pueden verse absorbidos por los valores de poblaciones mas grandes, por ello elijo la mediana que puede ser un estadístico más robusto. Para los campos cualitativos, que son pocos, creo que la mejor solución sería, por como son estos campos, dar valores aleatorios.

In [68]:
```
for col in numericas:
    df[col] = ImputacionCuant(df[col], 'mediana')

for col in categoricas:
    df[col] = ImputacionCuali(df[col], 'aleatorio')

# Reviso que no queden datos missings
df.isna().sum()
```

Out[68]:
```
Name                          0
CodigoProvincia               0
CCAA                          0
Population                    0
TotalCensus                   0
AbstentionPtge                0
AbstencionAlta                0
Izda_Pct                      0
Dcha_Pct                      0
Otros_Pct                     0
Izquierda                     0
Derecha                       0
Age_0-4_Ptge                  0
Age_under19_Ptge              0
Age_19_65_pct                 0
Age_over65_pct                0
WomanPopulationPtge           0
ForeignersPtge                0
SameComAutonPtge              0
SameComAutonDiffProvPtge      0
DifComAutonPtge               0
UnemployLess25_Ptge           0
Unemploy25_40_Ptge            0
UnemployMore40_Ptge           0
AgricultureUnemploymentPtge   0
IndustryUnemploymentPtge      0
ConstructionUnemploymentPtge  0
ServicesUnemploymentPtge      0
totalEmpresas                 0
Industria                     0
Construccion                  0
ComercTTEHosteleria           0
Servicios                     0
ActividadPpal                 0
inmuebles                     0
Pob2010                       0
SUPERFICIE                    0
Densidad                      0
PobChange_pct                 0
PersonasInmueble              0
Explotaciones                 0
dtype: int64
```

In [69]:
```
X_miss = df.drop(columns=out_variables_dependientes+["Name", "CodigoProvincia"])
X = X_miss
```

7. Detección de las relaciones entre las variables.

Antes de realizar la detección de las relaciones entre las variables vamos a echar un vistacillo en el excel y la definición de cada campo para encontrar alguna posible colinealidad. Aquellas que he detectado a simple vista son:

- `totalEmpresas` con [Industria, Construccion, ComercTTEHosteleria, Servicios], puesto es un sumatorio de la lista de las posibles empresas, en otros casos no dan valores a la lista y únicamente tenemos el total de empresas.

- `ActividadPpal` con [Industria, Construccion, ComercTTEHosteleria, Servicios], en este caso el campo "ActividaPpal" nos muestra cual es la actividad predominante entre estas 4. Cuando no están notificados los valores de industria... nos da la etiqueta de "Otros"
- `Densidad` con `Poblacion` y `SUPERFICIE`. Estas variables deberían seguir la relacion: $Densidad = \frac{Poblacion}{SUPERFICIE}$ por lo que, aunque no se pueda detectar una relación lineal, debe haber una relación.
- `PersonasInmuebles` con `inmuebles` y `Poblacion`. También debería seguir la relación $PersonasInmuebles = \frac{Poblacion}{inmuebles}$. Con lo que estamos en el mismo caso que antes

7.1. Detección de las relaciones entre las variables input continuas.

In [ ]:
```
def Vcramer(v, target):
    """
    Calcula el coeficiente V de Cramer entre dos variables. Si alguna de ellas e

    Datos de entrada:
    - v: Serie de datos categóricos o cuantitativos.
    - target: Serie de datos categóricos o cuantitativos.

    Datos de salida:
    - Coeficiente V de Cramer que mide la asociación entre las dos variables.
    """

    if v.dtype == 'float64' or v.dtype == 'int64':

        # Si v es numérica, la discretiza en intervalos y rellena los valores fa
        p = sorted(list(set(v.quantile([0, 0.2, 0.4, 0.6, 0.8, 1.0]))))
        v = pd.cut(v, bins=p)
        v = v.fillna(v.min())

    if target.dtype == 'float64' or target.dtype == 'int64':

        # Si target es numérica, la discretiza en intervalos y rellena los valor
        p = sorted(list(set(target.quantile([0, 0.2, 0.4, 0.6, 0.8, 1.0]))))
        target = pd.cut(target, bins=p)
        target = target.fillna(target.min())

    v = v.reset_index(drop=True)
    target = target.reset_index(drop=True)

    # Calcula una tabla de contingencia entre v y target
    tabla_cruzada = pd.crosstab(v, target)
    # Calcula el chi-cuadrado y el coeficiente V de Cramer
    chi2 = chi2_contingency(tabla_cruzada)[0]
    n = tabla_cruzada.sum().sum()

    v_cramer = np.sqrt(chi2 / (n * (min(tabla_cruzada.shape) - 1)))

    return v_cramer
```

In [119…
```
# Calcular matriz de correlación
corr_matrix = X.corr()
```

```
# Crear el heatmap con Seaborn
sns.set(font_scale=0.5)
plt.figure(figsize=(8, 6))
sns.heatmap(corr_matrix, annot=False, cmap='coolwarm', fmt=".2f", linewidths=0.5

# Mostrar el gráfico
plt.title("Matriz de Correlación")
plt.show()
```

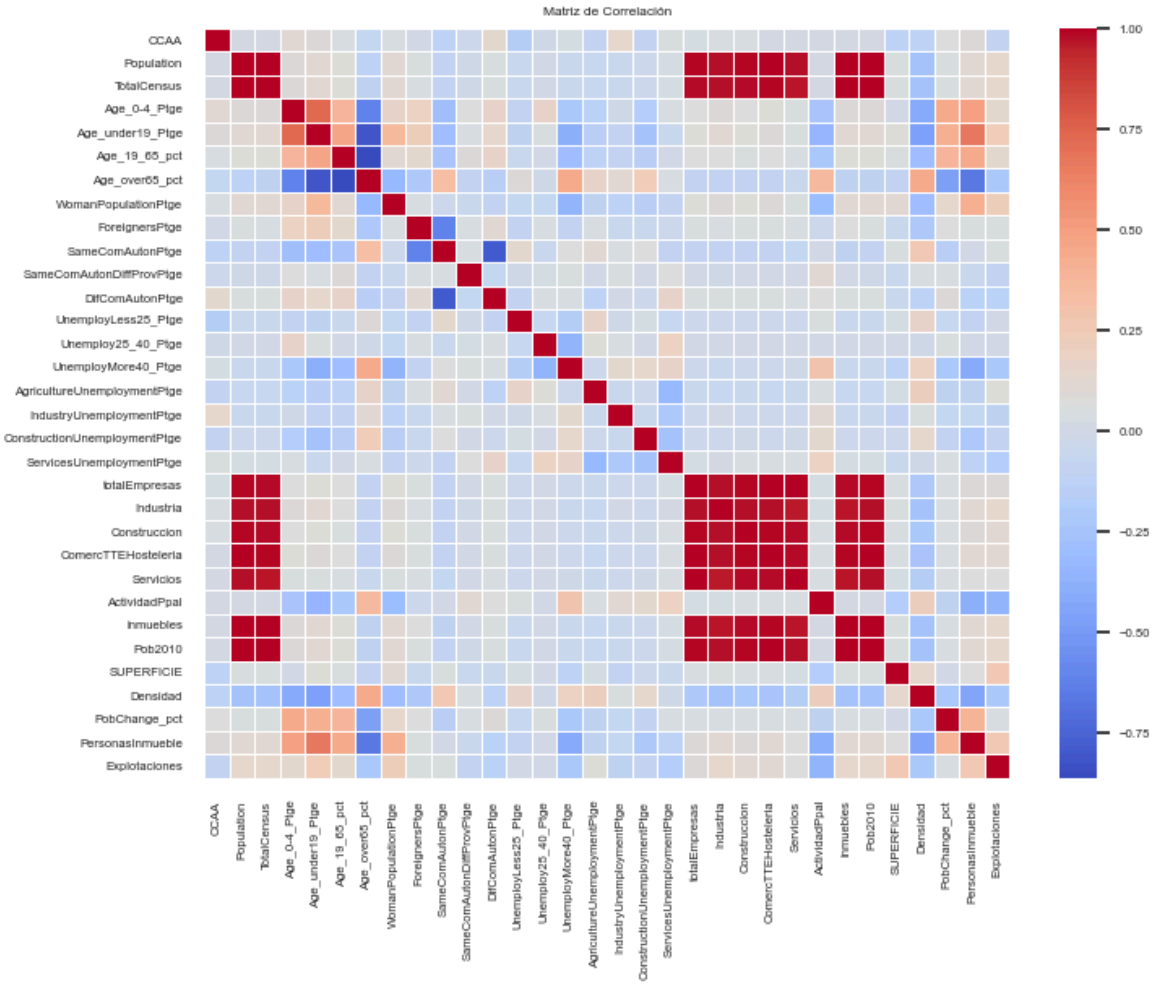

Como podemos ver en la imagen anterior se confirma algunas de las predicciones anteriores y podemos nuevas correlaciones:

- `Total de empresas` se relaciona linealmente con [Industria, Construccion, ComercTTEHosteleria, Servicios]
- `Inmuebles` y `Población` tienen una alta correlación, lo cual es compresible, ya que cuantos más habitantes, más inmuebles.
- Además `Inmuebles` y `Población` tienen relación con [Industria, Construccion, ComercTTEHosteleria, Servicios], por el mismo razonamiento anterior
- Los porcentages de edades se relacionan linealmente de manera negativa, cuanto más porcentage hay de uno, menos porcentage habrá de los otros
- `DifcomAuton` y `SamecomAuto` relacion lineal negativa, por el mismo razonamiento anterior. Probablemente sea recomendable eliminar esta variable

7.2. Relaciones entre todas las variables input y cada una de las variables objetivo

No entiendo como es posible que en el chi cuadrado (en el caso de la variable dicotomica) me esté sacando de estadístico=0, generando problemas al sacar la chi2

In [133…

```
VCramer_df = pd.DataFrame(columns=['Variable', 'Vcramer'])
for campo in X.columns:
    v_cramer = Vcramer(X[campo], Y_cont)
    nuevo_cramer = pd.DataFrame({'Variable': [campo], 'Vcramer': [v_cramer]})
    VCramer_df = pd.concat([VCramer_df, nuevo_cramer], ignore_index=True)

VCramer_df
```

Out[133...

	Variable	Vcramer
0	CCAA	0.312701
1	Population	0.215627
2	TotalCensus	0.216113
3	Age_0-4_Ptge	0.156607
4	Age_under19_Ptge	0.162203
5	Age_19_65_pct	0.108037
6	Age_over65_pct	0.159166
7	WomanPopulationPtge	0.122935
8	ForeignersPtge	0.079916
9	SameComAutonPtge	0.044350
10	SameComAutonDiffProvPtge	0.076210
11	DifComAutonPtge	0.025955
12	UnemployLess25_Ptge	0.128469
13	Unemploy25_40_Ptge	0.103966
14	UnemployMore40_Ptge	0.105681
15	AgricultureUnemploymentPtge	0.141412
16	IndustryUnemploymentPtge	0.126916
17	ConstructionUnemploymentPtge	0.111830
18	ServicesUnemploymentPtge	0.087211
19	totalEmpresas	0.204508
20	Industria	0.279781
21	Construccion	0.299052
22	ComercTTEHosteleria	0.306475
23	Servicios	0.301930
24	ActividadPpal	0.177495
25	inmuebles	0.201941
26	Pob2010	0.212896
27	SUPERFICIE	0.060708
28	Densidad	0.183310
29	PobChange_pct	0.115161
30	PersonasInmueble	0.164652
31	Explotaciones	0.114256

In [137…
```
VCramer_df = VCramer_df.sort_values(by="Vcramer")

plt.figure(figsize=(15, 15))
sns.barplot(x="Variable", y="Vcramer", data=VCramer_df, color='skyblue')


plt.title("Histograma con Seaborn")
plt.xticks(rotation=45)
plt.show()
```

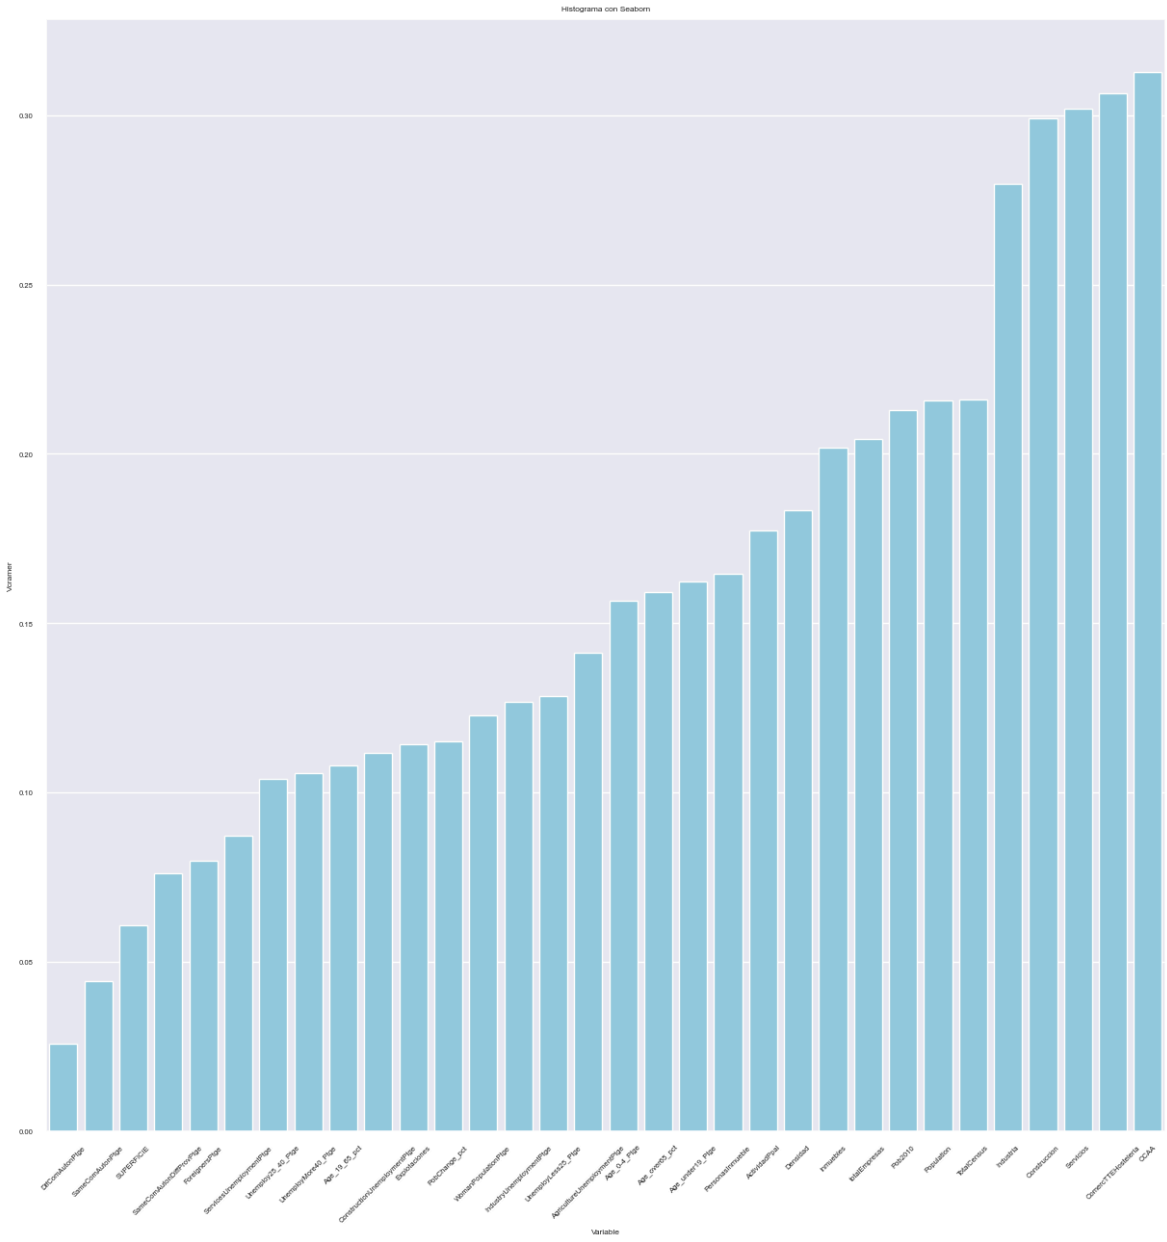

Por lo que parece nuestra variable dependiente continua, depende en gran medida de la CCAA y de los sectores de trabajo de una manera parecida, lo cual puede significar que tal vez en las poblaciones con mas población, suele haber más abstención, como nos muestra `Population` que también tiene un alto valor de Vdecramer

In [130…
```
VCramer_df = pd.DataFrame(columns=['Variable', 'Objetivo', 'Vcramer'])
for campo in X.columns:
    v_cramer = Vcramer(X[campo], Y_dico)
    nuevo_cramer = pd.DataFrame({'Variable': [campo], 'Objetivo': [Y_cont.name],
    VCramer_df = pd.concat([VCramer_df, nuevo_cramer], ignore_index=True)
```

```
VCramer_df
```

Out[130…

	Variable	Objetivo	Vcramer
0	CCAA	AbstentionPtge	NaN
1	Population	AbstentionPtge	NaN
2	TotalCensus	AbstentionPtge	NaN
3	Age_0-4_Ptge	AbstentionPtge	NaN
4	Age_under19_Ptge	AbstentionPtge	NaN
5	Age_19_65_pct	AbstentionPtge	NaN
6	Age_over65_pct	AbstentionPtge	NaN
7	WomanPopulationPtge	AbstentionPtge	NaN
8	ForeignersPtge	AbstentionPtge	NaN
9	SameComAutonPtge	AbstentionPtge	NaN
10	SameComAutonDiffProvPtge	AbstentionPtge	NaN
11	DifComAutonPtge	AbstentionPtge	NaN
12	UnemployLess25_Ptge	AbstentionPtge	NaN
13	Unemploy25_40_Ptge	AbstentionPtge	NaN
14	UnemployMore40_Ptge	AbstentionPtge	NaN
15	AgricultureUnemploymentPtge	AbstentionPtge	NaN
16	IndustryUnemploymentPtge	AbstentionPtge	NaN
17	ConstructionUnemploymentPtge	AbstentionPtge	NaN
18	ServicesUnemploymentPtge	AbstentionPtge	NaN
19	totalEmpresas	AbstentionPtge	NaN
20	Industria	AbstentionPtge	NaN
21	Construccion	AbstentionPtge	NaN
22	ComercTTEHosteleria	AbstentionPtge	NaN
23	Servicios	AbstentionPtge	NaN
24	ActividadPpal	AbstentionPtge	NaN
25	inmuebles	AbstentionPtge	NaN
26	Pob2010	AbstentionPtge	NaN
27	SUPERFICIE	AbstentionPtge	NaN
28	Densidad	AbstentionPtge	NaN
29	PobChange_pct	AbstentionPtge	NaN
30	PersonasInmueble	AbstentionPtge	NaN
31	Explotaciones	AbstentionPtge	NaN

8. Construccion de regresion lineal

8.1 Mediante los métodos de selección clásica de variables

8.1.1. Forward selection

Genero la partición de datos. Pero antes debo convertir las variables categoricas en numeros para que puedan ser leidas por el programa.

He intentado implementar de todas las maneras posibles todas los metodos clasicos de variables pero me da un error constantemente en la interaccion 30 debido a que parece que se modifica (no se como) los datos de X o Y he intentado todo pero no puedo. El entorno tampoco me iba, al final por falta de tiempo lo he dejado así. Siento mucho no haberlo podido terminar de ninguna manera, he investigado mucho y entre que soy medio nuevo en programación y en estadística, pues tardo demasiado para cada cosa.

In [73]:
```
le = LabelEncoder()
for categorica in categoricas:
    X[categorica] = le.fit_transform(X[categorica])
```

In [74]:
```
print(X.dtypes)
```

```
CCAA                          int32
Population                    int64
TotalCensus                   int64
Age_0-4_Ptge                float64
Age_under19_Ptge            float64
Age_19_65_pct               float64
Age_over65_pct              float64
WomanPopulationPtge         float64
ForeignersPtge              float64
SameComAutonPtge            float64
SameComAutonDiffProvPtge    float64
DifComAutonPtge             float64
UnemployLess25_Ptge         float64
Unemploy25_40_Ptge          float64
UnemployMore40_Ptge         float64
AgricultureUnemploymentPtge float64
IndustryUnemploymentPtge    float64
ConstructionUnemploymentPtge float64
ServicesUnemploymentPtge    float64
totalEmpresas               float64
Industria                   float64
Construccion                float64
ComercTTEHosteleria         float64
Servicios                   float64
ActividadPpal                 int32
inmuebles                   float64
Pob2010                     float64
SUPERFICIE                  float64
Densidad                      int32
PobChange_pct               float64
PersonasInmueble            float64
Explotaciones               float64
dtype: object
```

In [75]:
```
x_train, x_test, y_train, y_test = train_test_split(X, Y_cont, test_size = 0.2,
X.head(5)
```

Out[75]:

	CCAA	Population	TotalCensus	Age_0-4_Ptge	Age_under19_Ptge	Age_19_65_pct	Age_ove
0	10	336	282	3.869	18.155	55.059	
1	10	429	364	1.632	13.055	56.643	
2	10	569	569	1.230	9.139	54.834	
3	10	822	704	4.258	14.964	60.098	
4	10	623	540	3.531	15.569	59.391	

In [76]:
```
np.any(np.isnan(y_train))
```

Out[76]: False

In [77]:
```
x_train.isna().any().any()
```

Out[77]: False

In [78]:
```
print(len(x_train))
print(len(y_train))
```

```
6493
6493
```

In [79]:
```
modelo_inicial = sm.OLS(y_train, np.ravel([1] * len(x_train))).fit()
```

In [86]:
```
def lm_forward_(varObjCont, datos, var_cont, var_categ, var_interac = [], metodo
    """
    Esta función realiza una selección de variables hacia adelante (step forward
    para un modelo de regresión lineal. El objetivo es encontrar el mejor conjun
    de variables para predecir 'varObjCont' utilizando el criterio 'metodo' (AIC

    Argumentos de entrada:
    - varObjCont: La variable objetivo (dependiente) que deseamos predecir.
    - datos: El DataFrame que contiene todas las variables.
    - var_cont: Una lista de nombres de variables continuas.
    - var_categ: Una lista de nombres de variables categóricas.
    - var_interac: Una lista de nombres de variables de interacción (por defecto
    - metodo: El criterio para seleccionar variables ('AIC' o 'BIC', por defecto

    Argumentos de salida:
    - Un modelo de regresión lineal que utiliza el mejor conjunto de variables e
    """
    print(x_train.isna().any().any())
    print(np.any(np.isnan(y_train)))
    # Crear una lista 'variables' que contiene todas las variables a considerar.
    variables = var_cont + var_categ + var_interac
    # Inicializar listas para almacenar las variables seleccionadas.
    var_cont_final, var_categ_final, var_interac_final = [], [], []

    # Definir la función 'calcular_metrica' dependiendo del método de bondad de
    if metodo == 'AIC':
        def calcular_metrica(modelo):
            return 2 * (modelo.df_model + 1) - 2 * modelo.llf
    elif metodo == 'BIC':
        def calcular_metrica(modelo):
            return np.log(len(datos)) * (modelo.df_model + 1) - 2 * modelo.llf

    # Ajustar un modelo inicial con una sola constante.
    modelo_inicial = sm.OLS(varObjCont, np.ones(len(datos))).fit()   ###########
    metrica_inicial = calcular_metrica(modelo_inicial)
    dif_metrica = 1

    print('Start: ' + metodo + ' = ' + str(metrica_inicial))
    print('')
    print('y ~ 1')
    print('')
    index2 = 0
    # Comenzar el bucle de selección de variables.
    while((dif_metrica > 0) and (len(variables) > 0)):
        variables_probar = []
        metricas = []
        index2 += 1
        print(index2)
        # Iterar a través de las variables restantes.
        index = 0
        for x in variables:
```

```
            index += 1
            print(index)
            var_cont_probar, var_categ_probar, var_interac_probar = var_cont_fin
            if x in var_cont:
                var_cont_probar = var_cont_final + [x]
            elif x in var_categ:
                var_categ_probar = var_categ_final + [x]
            else:
                var_interac_probar = var_interac_final + [x]

            # Ajustar un modelo con la variable actual y calcular la métrica.
            modelo = lm(varObjCont, datos, var_cont_probar, var_categ_probar, va
            variables_probar.append(x)
            metricas.append(calcular_metrica(modelo))

        # Imprimir métricas de AIC/BIC para las variables probadas.
        print(pd.DataFrame({
            'Variable': [' + ' + str(x) for x in variables_probar], metodo: metr
            }).sort_values(metodo).to_string(index = False))
        print('')

        # Elegir la mejor variable y su métrica actual.
        mejor_variable = variables_probar[min(enumerate(metricas), key = lambda
        metrica_actual = metricas[min(enumerate(metricas), key = lambda x: x[1])

        # Agregar la mejor variable al conjunto final apropiado.
        if mejor_variable in var_cont:
            var_cont_final.append(mejor_variable)
        elif mejor_variable in var_categ:
            var_categ_final.append(mejor_variable)
        else:
            var_interac_final.append(mejor_variable)

        # Actualizar la diferencia en métrica, las variables y el modelo inicial
        dif_metrica = metrica_inicial - metrica_actual
        variables = [x for x in variables if x != mejor_variable]
        metrica_inicial = metrica_actual
        modelo_inicial = modelo

        # Gestionar la eliminación de variables si la métrica no mejora.
        if dif_metrica <= 0:
            if mejor_variable in var_cont:
                var_cont_final = [x for x in var_cont_final if x != mejor_variab
            elif mejor_variable in var_categ:
                var_categ_final = [x for x in var_categ_final if x != mejor_vari
            else:
                var_interac_final = [x for x in var_interac_final if x != mejor_
        else:
            # Imprimir el modelo y la métrica actual si la métrica mejora.
            formula = ' + '.join(var_cont_final + var_categ_final + ['*'.join(x)
            print('------------------------------------ Step Forward: Entra '
            print('')
            print('AIC = ' + str(metrica_inicial))
            print('')
            print('y ~ ' + formula)
            print('')

    # Devolver el modelo final con el conjunto de variables seleccionado.
    return lm(varObjCont, datos, var_cont_final, var_categ_final, var_interac_fi
```

In [88]:
```
# Creo el modelo
interacciones = list(itertools.combinations(numericas,2))
numericas= list(numericas)
#modelo1 = lm_forward_(y_train, x_train, numericas, categoricas, interacciones,
# La funcion de arriba es la que me da problemas
```